

**VISOKA ŠKOLA ZA SAVREMENO POSLOVANJE,
INFORMACIONE TEHNOLOGIJE I TRŽIŠNE
KOMUNIKACIJE „INTERNACIONALNA POSLOVNO-
INFORMACIONA AKADEMIJA” TUZLA**

Case Study II - izvještaj

**Airbnb cjenovni obrasci u mediteranskim gradovima:
uloga lokacije, tipa smještaja i lokalnih tržišnih uvjeta**

Profesor:

mr. Selena Kurtić, dipl.ing.el.

Studenti:

Belma Salkićić

Ajnur Nukić

Demir Halilbašić

Tuzla, maj 2026.

SAŽETAK

Rad istražuje faktore koji određuju cijenu smještaja na Airbnb platformi, s fokusom na uticaj geografske lokacije i tipa smještaja u šest mediteranskih i južnoevropskih gradova: Ateni, Malagi, Istanbulu, Napulju, Rimu i Valenciji. Analiza je provedena na uzorku od 91.301 oglasa preuzetih s platforme Inside Airbnb za period septembar-oktobar 2025. godine, uz primjenu deskriptivne statistike, geospacijalne analize, regresijskih modela i klasterizacije.

Rezultati pokazuju da Rim prednjači kao najskuplje tržište (medijan 126 EUR), dok su Atena i Napulj pristupačniji. Tip smještaja pokazao se kao dominantniji cjenovni faktor u odnosu na lokaciju u pet od šest gradova, s izuzetkom Rima gdje oba faktora imaju uravnotežen uticaj. Hipoteza o cjenovnoj premiji cijelog stana/kuće potvrđena je bez iznimke u svim gradovima. Geospacijalna analiza otkriva da veza između centralnosti i cijene nije univerzalna. Istanbul i Napulj pokazuju atipične obrasce u kojima lokacija ne determinira cijenu na očekivani način. Istraživanje identificira Atenu i Istanbul kao gradove s najboljim omjerom cijene i kvalitete, te ukazuje na značajan udio nelicenciranog poslovanja u Istanbulu i Valenciji.

SADRŽAJ

1	UVOD I ISTRAŽIVAČKO PITANJE	1
2	DATASET & METODOLOGIJA	2
2.1	Izvori podataka.....	2
2.2	Priprema i čišćenje podataka	2
2.3	Metodološki pristup	3
3	VIZUALIZACIJA PODATAKA.....	4
3.1	Distribucija cijena po gradovima	4
3.2	Geospacijalna analiza.....	5
3.3	Analiza tipa smještaja i komparacija gradova	7
3.4	Analiza hostova.....	10
3.5	Recenzije i ocjene	11
3.6	Regresijska analiza - lokacija vs. tip smještaja	13
3.7	Napredna analiza.....	14
4	ZAKLJUČAK.....	16
	LITERATURA.....	17

1 UVOD I ISTRAŽIVAČKO PITANJE

Digitalne platforme kratkoročnog iznajmljivanja, posebno Airbnb, transformirale su globalno turističko tržište u posljednjem desetljeću. Sa više od 7 miliona aktivnih oglasa u više od 200 zemalja, Airbnb danas predstavlja jedan od najvećih skupova podataka o urbanoj turističkoj potražnji i kao takav, iznimno je vrijedan izvor za istraživanje cjenovnih obrazaca na različitim tržištima.

Istraživanje polazi od temeljnog pitanja koji faktori određuju cijenu smještaja na Airbnb platformi, te da li ti faktori djeluju jednako u različitim urbanim sredinama. U fokusu su dva bazična prediktora: geografska lokacija smještaja unutar grada (centralni vs. periferni kvartovi) i tip smještaja (cijeli stan/kuća, privatna soba, zajednička soba). Analiza je provedena na uzorku od šest mediteranskih i južnoevropskih gradova - Atena, Malaga, Istanbul, Napulj, Rim, Valencia koji dijele određene turističke karakteristike, ali se značajno razlikuju po veličini tržišta, ekonomskom kontekstu i turističkom pritisku.

Centralna hipoteza (H_0) istraživanje glasi:

Cijena Airbnb smještaja determinirana je kombinacijom geografske lokacije i tipa smještaja, pri čemu relativna važnost ovih faktora nije uniformna - već se sistematski razlikuje između gradova ovisno o lokalnim tržišnim uvjetima.

Iz ove hipoteze su proizašle tri pomoćne hipoteze koje se testiraju kroz analizu:

- **H1** - Smještaji u centralnim kvartovima imaju statistički višu prosječnu cijenu u odnosu na periferiju, no intenzitet ovog efekta varira po gradu.
- **H2** - Iznajmljivanje cijelog stana nosi cjenovnu premiju u odnosu na privatnu sobu, no veličina premije ovisi o lokalnom tržišnom kontekstu.
- **H3** - U gradovima s višim turističkim pritiskom lokacija dominira kao cjenovni faktor, dok u manjim tržištima tip smještaja postaje relativno važniji prediktor.

Cilj istraživanja je identificirati gradove i kvartove koji statistički odudaraju od očekivanih obrazaca - čime se otvara prostor za razumijevanje specifičnih lokalnih faktora koji oblikuju tržišta kratkoročnog iznajmljivanja.

2 DATASET & METODOLOGIJA

2.1 Izvori podataka

Istraživanje koristi podatke preuzete sa platforme Inside Airbnb (insideairbnb.com), neprofitnog projekta koji prikuplja i objavljuje javno dostupne podatke s Airbnb platforme u svrhu akademskih i istraživačkih analiza. Za svaki od šest gradova korištena su dva tipa datoteka:

- listings.csv - glavni skup podataka koji sadrži informacije o svakom oglasu: cijenu smještaja, geografske koordinate (latitude/longitude), tip sobe, broj recenzija, dostupnost i pripadajući kvart
- neighbourhoods.geojson - geospacijalni podaci o granicama kvartova, korišteni za izradu kartografskih vizualizacija

Podaci su preuzeti za sljedeće gradove i periode scrappinga:

Tabela 1: Podaci i period scrappinga

Grad	Regija	Datum preuzimanja
Atena	Attica, Grčka	26. septembar 2025.
Malaga	Andaluzija, Španija	30. septembar 2025.
Istanbul	Marmara, Turska	29. septembar 2025.
Napulj	Kampanija, Italija	22. septembar 2025.
Rim	Lazio, Italija	14. septembar 2025.
Valencia	Valencia, Španija	23. septembar 2025.

Izvor: Kreacija autora.

Svi podaci reflektuju stanje tržišta u periodu septembar-oktobar 2025. godine.

2.2 Priprema i čišćenje podataka

Prije analize, svaki dataset je prošao standardni proces čišćenja koji je uključivao uklanjanje oglasa s nedostajućim ili nevalidnim vrijednostima cijena, uklanjanje ekstremnih outliera, računanje udaljenosti od centra grada i konverziju cijene u USD po aproksimativnom kursu.

2.3 Metodološki pristup

Analiza je strukturirana u pet faza koje direktno korespondiraju s postavljenim hipotezama:

- **Distribucija cijena** - deskriptivna statistika i vizualizacija raspodjele cijena po svakom gradu, s ciljem razumijevanja osnovnih karakteristika svakog tržišta prije komparacije.
- **Geospacijalna analiza** - kartografsko prikazivanje prosječnih cijena po kvartovima (heatmapa) za svaki grad, uz identifikaciju centralnih i perifernih zona, kao i testiranje H1 hipoteze o uticaju lokacije.
- **Analiza tipa smještaja** - komparacija prosječnih cijena između kategorija *Entire home/apt*, *Private room* i *Shared room*, uz testiranje H2 hipoteze o cjenovnoj premiji cijelog stana.
- **Komparativna analiza gradova** - direktno poređenje metrika metrika svih šest gradova u cilju testiranja H3 hipoteze o varijabilnosti faktora po tržištu.
- **Napredna analiza** - identifikacija statističkih outliera i kvartova koji odudaraju od očekivanih obrazaca, uz analizu host karakteristika i korelacije recenzija s cijenom.

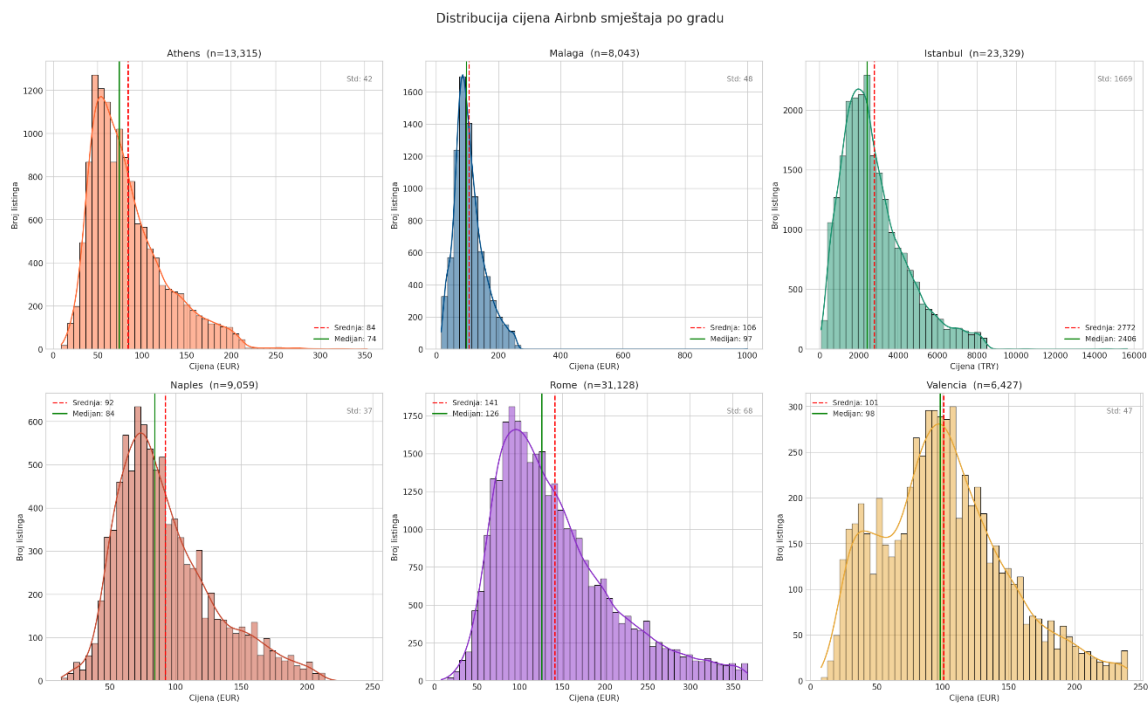
Sva analiza provedena je u programskom jeziku Python, korištenjem skupa specijaliziranih biblioteka odabranih prema zahtjevima svake analitičke faze. Manipulacija, čišćenje i transformacija podataka realizirane su putem biblioteka Pandas i NumPy, uključujući parsiranje cijena, filtriranje outliera IQR metodom te konverziju valuta u zajedničku USD bazu. Za statističke vizualizacije, uključujući histogram i KDE distribucije, boxplot i violin plot komparacije te scatter i regresijske dijagrame, korištene su biblioteke Matplotlib i Seaborn. Interaktivni geospacijalni prikazi u vidu choropleth heatmapa i trodimenzionalnih scatter mapa implementirani su putem biblioteka Folium i Plotly. Statistički testovi hipoteza, obuhvatajući jednosmjernu ANOVA-u, Kruskal-Wallis test te Pearson i Spearman korelacijske analize, provedeni su korištenjem biblioteke SciPy, dok je višestruka OLS regresija implementirana putem biblioteke Statsmodels. Segmentacija tržišnih segmenata metodom KMeans klasterizacije realizirana je putem biblioteke Scikit-learn, gdje je izračun geodetske udaljenosti listinga od centra grada proveden je putem biblioteke Geopy.

3 VIZUALIZACIJA PODATAKA

3.1 Distribucija cijena po gradovima

Svih šest tržišta dijeli zajedničku karakteristiku: desno asimetričnu raspodjelu cijena, gdje velika većina oglasa gravitira nižem cjenovnom razredu, dok manji broj premium smještaja formira dugački gornji rep. Ovaj obrazac opravdava korištenje medijana kao reprezentativnije mjere od aritmetičke sredine.

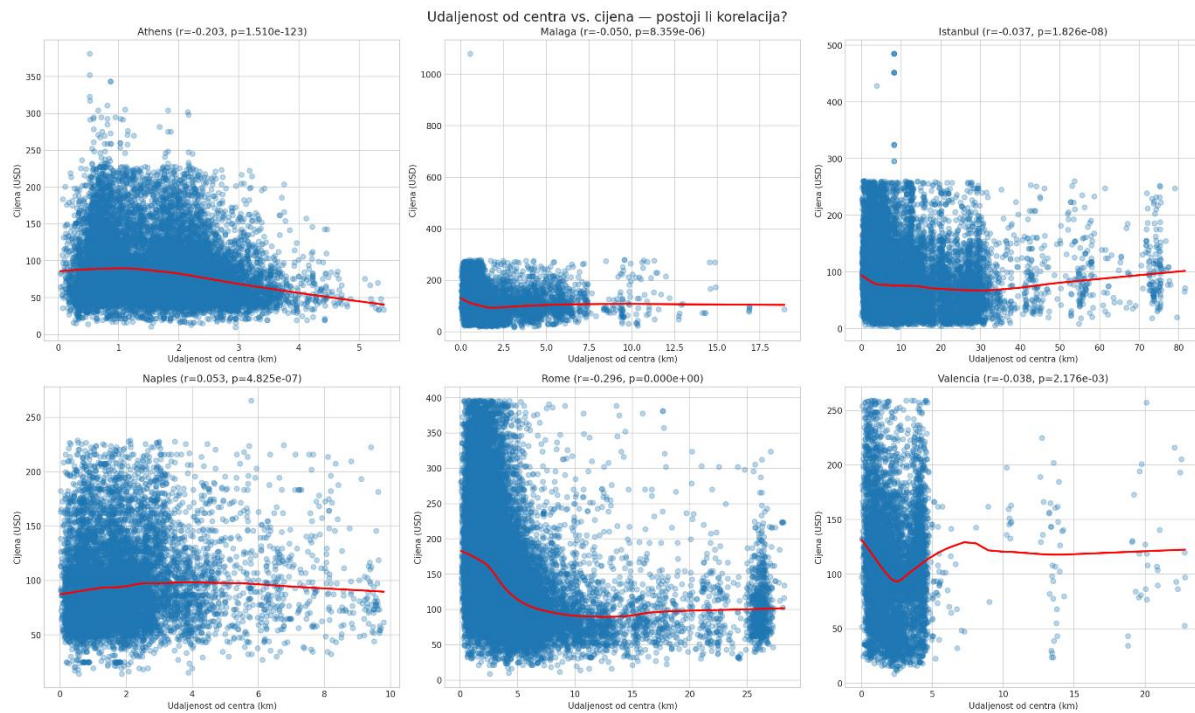
Rim je najskuplje tržište (medijan 126 EUR, prosječna cijena 141 EUR, $n=31.128$), dok su Atena (medijan 74 EUR) i Napulj (medijan 84 EUR) pristupačnija tržišta. Malaga i Valencia zauzimaju srednju poziciju (~97-98 EUR). Istanbul je specifičan jer su cijene izražene u turskim lirama, a nakon konverzije pozicionira se kao jedno od pristupačnijih tržišta. Violin plot po tipu smještaja potvrđuje da Entire home/apt ima najširu raspodjelu s visokim gornjim repom, dok Shared room bilježi konzistentno najniže cijene u svim gradovima.



Slika 1: Distribucija cijena po gradu


3.2 Geospacijalna analiza

Karte gustoće listinga pokazuju izrazitu prostornu koncentraciju ponude u svim gradovima. Atena i Napulj imaju gotovo cjelokupnu ponudu lociranu u uskom historijskom centru, dok Istanbul kao najveće tržište (n=23.329) pokazuje rasprošireniju ponudu s dominacijom evropskog dijela oko Beyoğlu i Beşiktaşa.

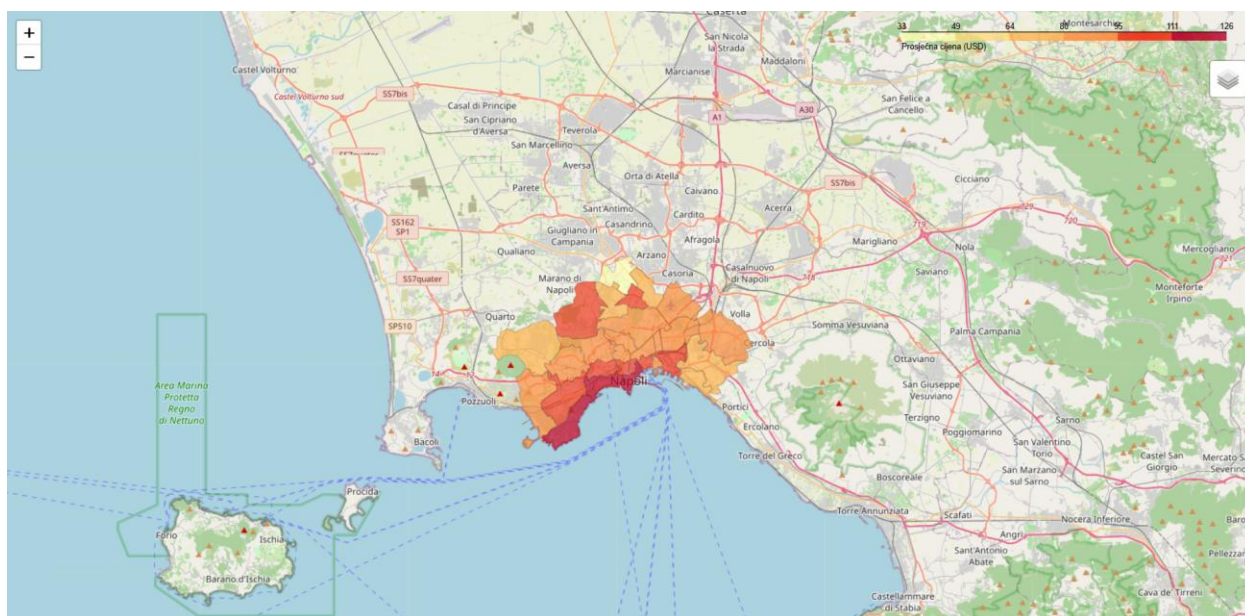


Slika 2: Razlika daljine od centra i cijene

Cjenovne heatmape direktno testiraju H1. Atena i Rim pokazuju najjasniju vezu između centralnosti i cijene: u Rimu kvart I Centro Storico dostiže ~185 USD prosječne cijene, gotovo duplo više od perifernih kvartova. Pearsonova korelacija udaljenosti i cijene iznosi $r = -0,296$ za Rim i najjača je u uzorku. U Ateni $r = -0,203$, dok Istanbul ($r = -0,037$) i Napulj ($r = +0,08$) pokazuju atipičan obrazac u kojemu centralna lokacija ne determinira cijenu. Napulj je jedini grad s pozitivnom korelacijom, što je posljedica premium obalnih kvartova poput Posillipa koji se nalaze izvan geografskog centra.



Slika 3: Heatmap Rima




Slika 4: Heatmap Napulja

3.3 Analiza tipa smještaja i komparacija gradova

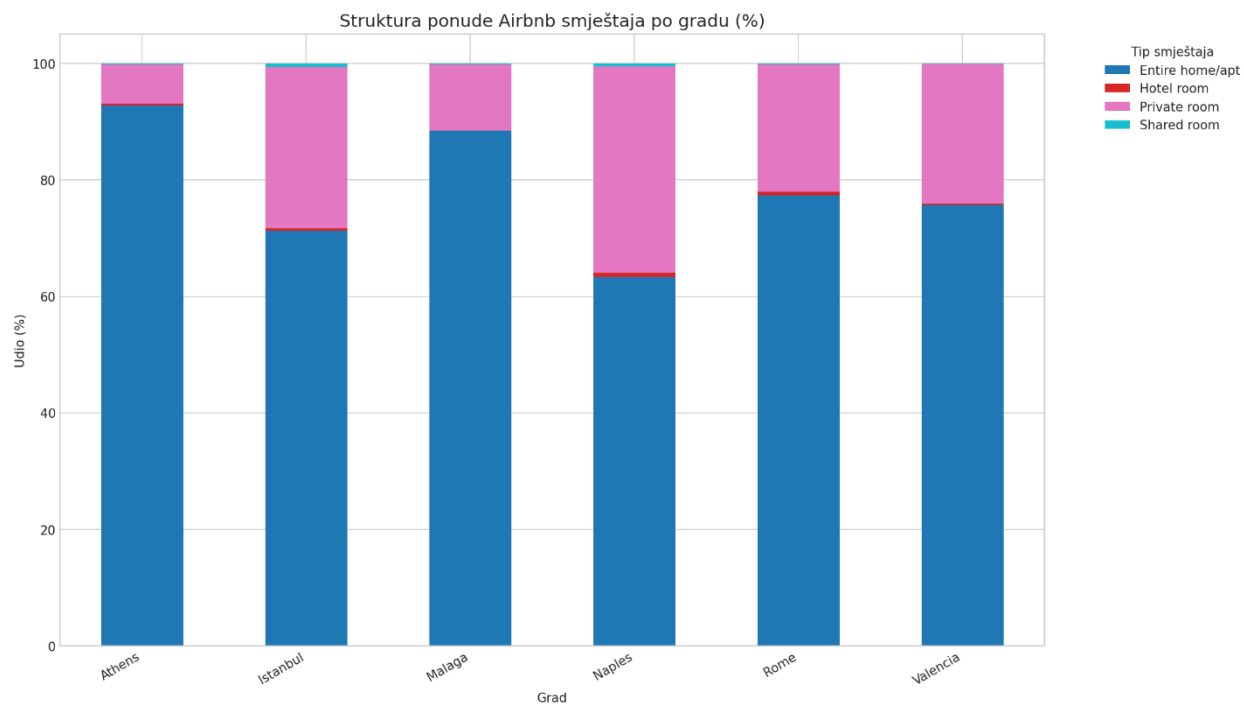
Entire home/apt konzistentno postiže višu cijenu od Private room u svih šest gradova, čime je H2 potvrđena bez iznimke. Premija je najveća u Rimu (~163 USD vs. ~120 USD za privatnu sobu). Struktura ponude dominantno je u korist cijelih stanova: od 93% u Ateni do 63% u Napulju, koji ima najdiversificiraniju strukturu.

Analiza vrijednosti za novac otkriva važan kontrast: Atena i Istanbul ostvaruju visoke ocjene vrijednosti (>4,7) uz niže apsolutne cijene, dok Rim bilježi najnižu percipiranu vrijednost za novac (~4,57) unatoč najvišim cijenama. Prosječna cijena po osobi potvrđuje Rim kao najskuplje tržište (~47 USD/osobi), a Istanbul kao najpristupačnije (~28 USD/osobi).



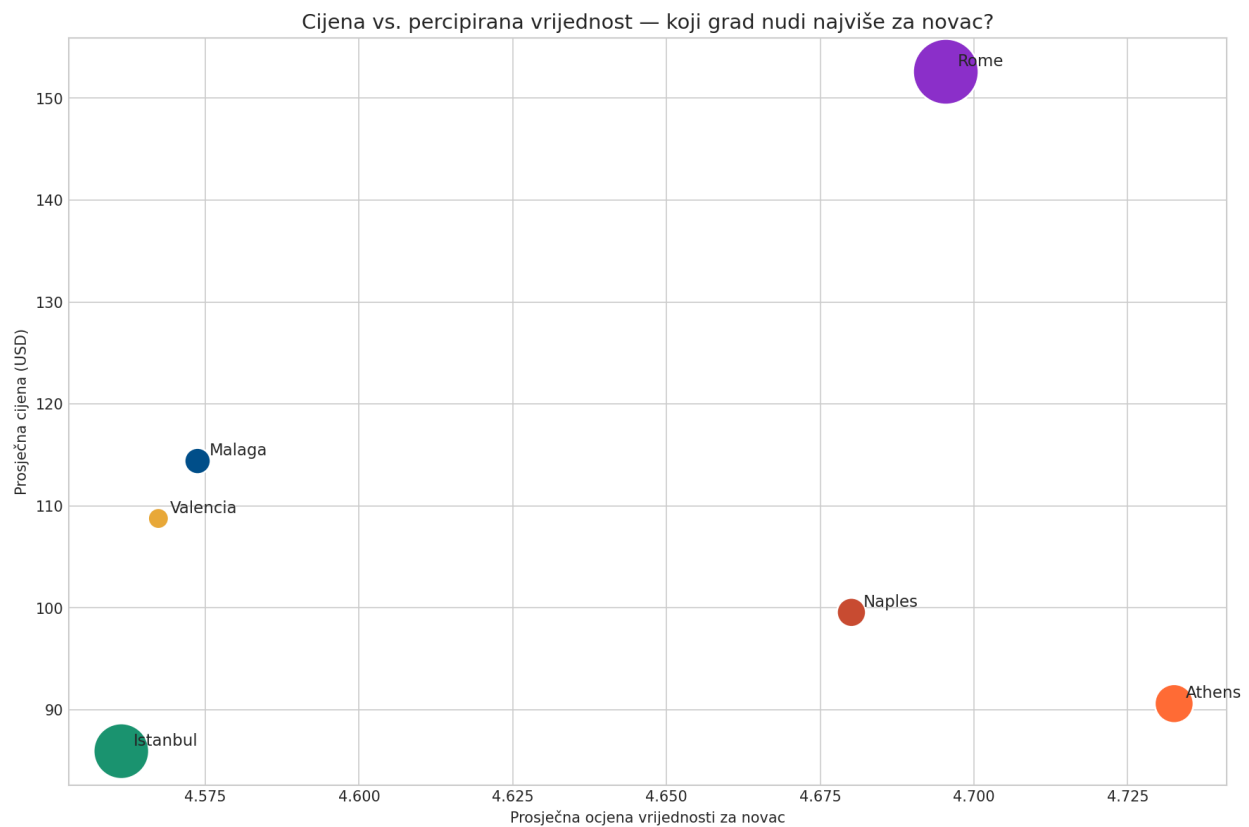
Slika 5: Distribucija cijena po tipu smještaja i gradu

Struktura ponude dominantno je u korist cijelih stanova u svim gradovima - od 93% u Ateni do 63% u Napulju, koji ima najdiversificiraniju strukturu s najvećim udjelom privatnih soba. Istanbul se izdvaja s udjelom od ~71% cijelih stanova, što je niže od mediteranskog prosjeka, dok Malaga i Valencia imaju udjele od ~88% i ~76% respektivno.



Slika 6: Struktura ponude Airbnb smještaja po gradu

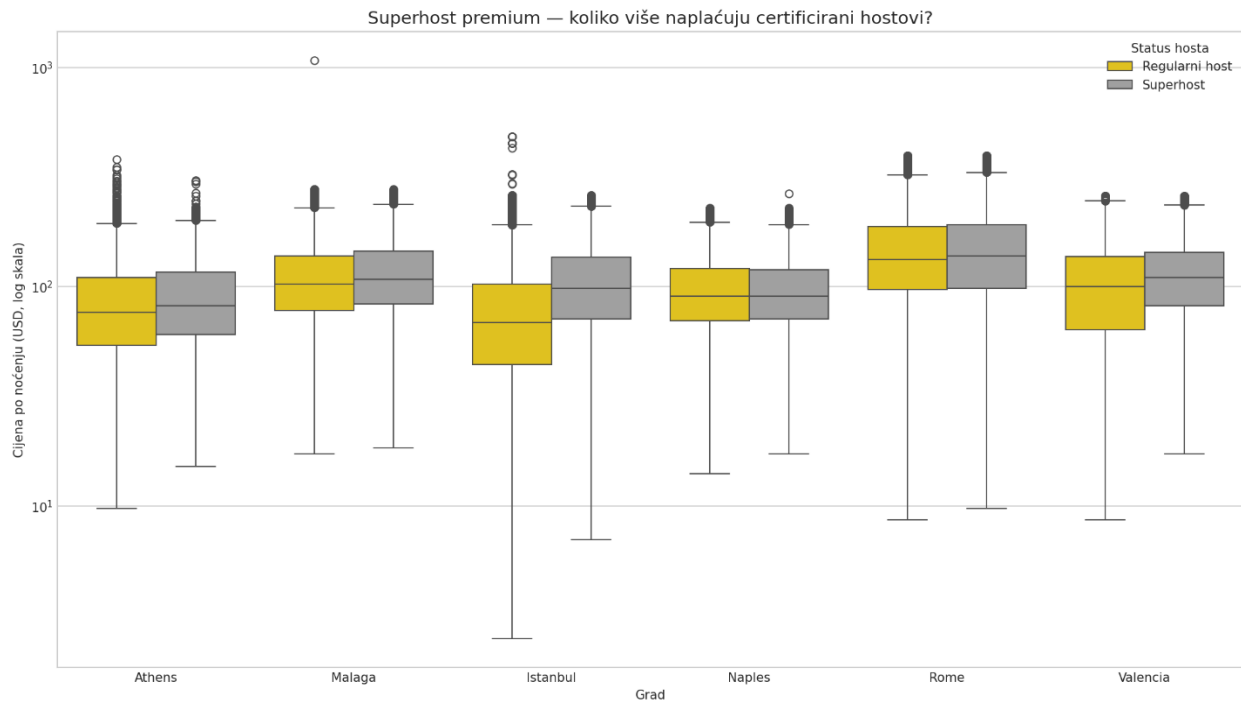
Analiza vrijednosti za novac otkriva važan paradoks: Atena i Istanbul ostvaruju visoke ocjene vrijednosti ($>4,7$) uz niže apsolutne cijene, dok Rim - unatoč najvišim cijenama - bilježi najnižu percipiranu vrijednost za novac ($\sim 4,57$). Ovo sugerira da gosti u Rimu cijene percipiraju kao visoke u odnosu na dobivenu uslugu, dok u Ateni i Istanbulu postoji snažniji osjećaj dobivene vrijednosti.



Slika 7: Cijena vs percipirana vrijednost

3.4 Analiza hostova

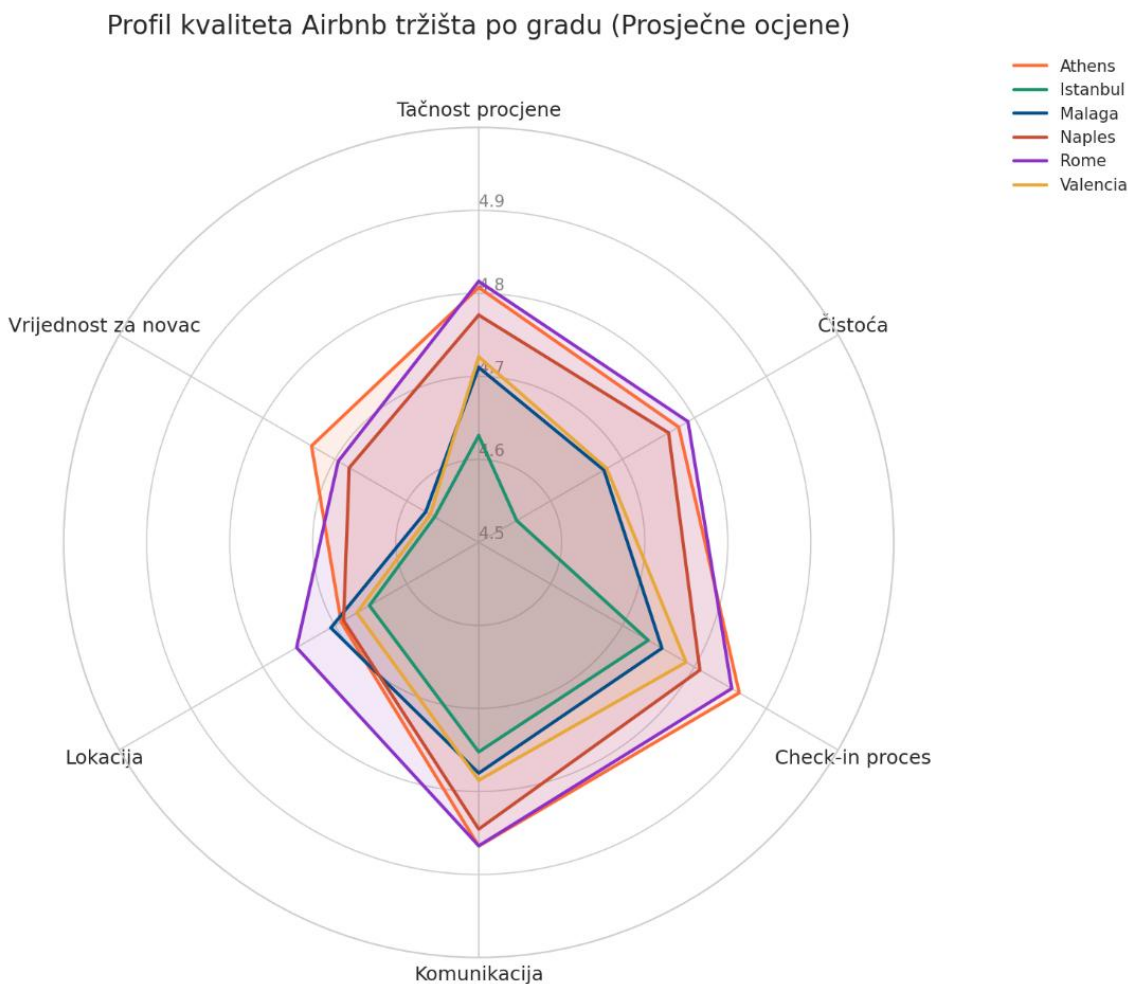
Distribucija hostova po broju listinga pokazuje bimodalnu strukturu u svim gradovima: većina hostova upravlja jednim oglasom, dok manji broj komercijalnih operatera drži i više od 100 listinga, posebno u Rimu i Istanbulu. Superhost certifikat nosi umjerenu cjenovnu premiju (5-15%), no ne predstavlja primarni uticaj na cijenu. Komercijalni hostovi (20+ listinga) naplaćuju tek ~6 USD više od privatnih (~112 vs. ~118 USD), što govori da tržišna konkurencija ograničava njihovu cjenovnu moć. Zanimljiv nalaz je i da smještaji s instant rezervacijom imaju višu prosječnu cijenu, ali nižu prosječnu ocjenu gostiju.



Slika 8: Superhost premium

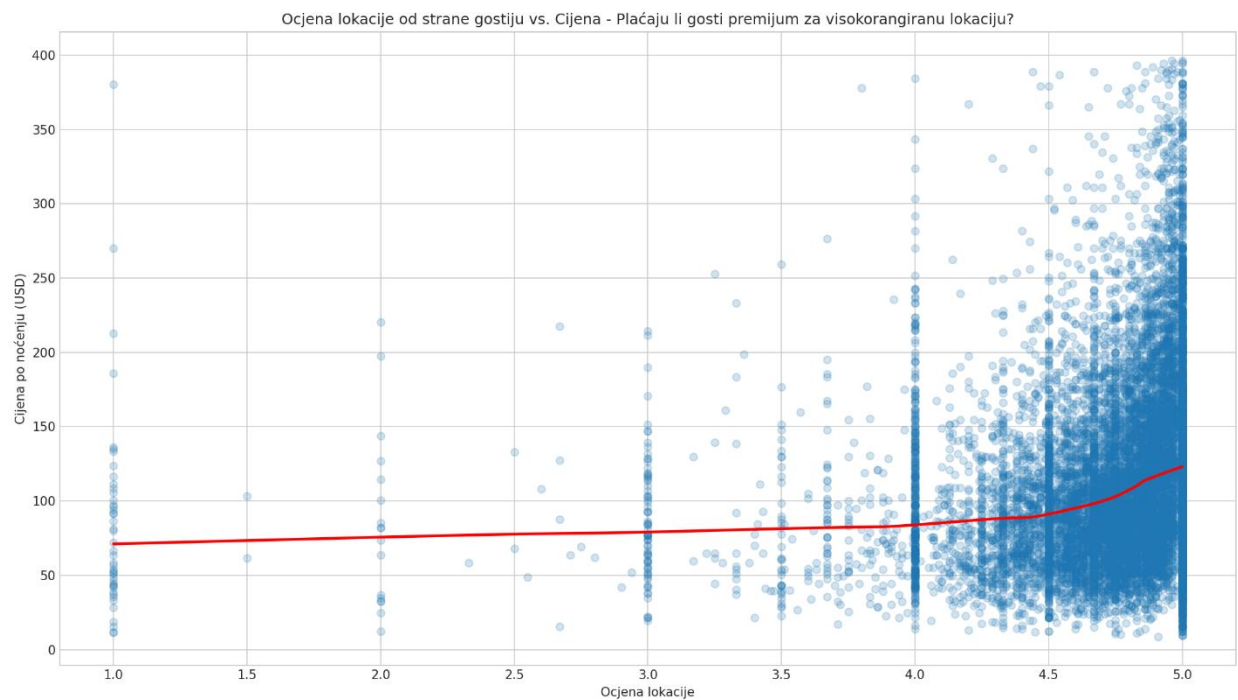
3.5 Recenzije i ocjene

Radar chart profila kvaliteta pokazuje da Napulj i Rim prednjače u dimenzijama komunikacije i check-in procesa, dok Istanbul bilježi najniže ocjene u gotovo svim kategorijama. Atena se ističe natprosječnim ocjenama vrijednosti za novac. Korelacijska matrica dimenzija ocjenjivanja konzistentno pokazuje da ukupna ocjena najjače korelira s tačnošću opisa ($r \sim 0,78-0,80$) i vrijednošću za novac ($r \sim 0,76-0,81$), dok ocjena lokacije ima najslabiju korelaciju s ukupnom ocjenom ($r \sim 0,39-0,47$) gosti svoju satisfakciju vezuju primarno uz uslugu, ne uz lokaciju.



Slika 9: Kvalitet Airbnb tržišta po gradu

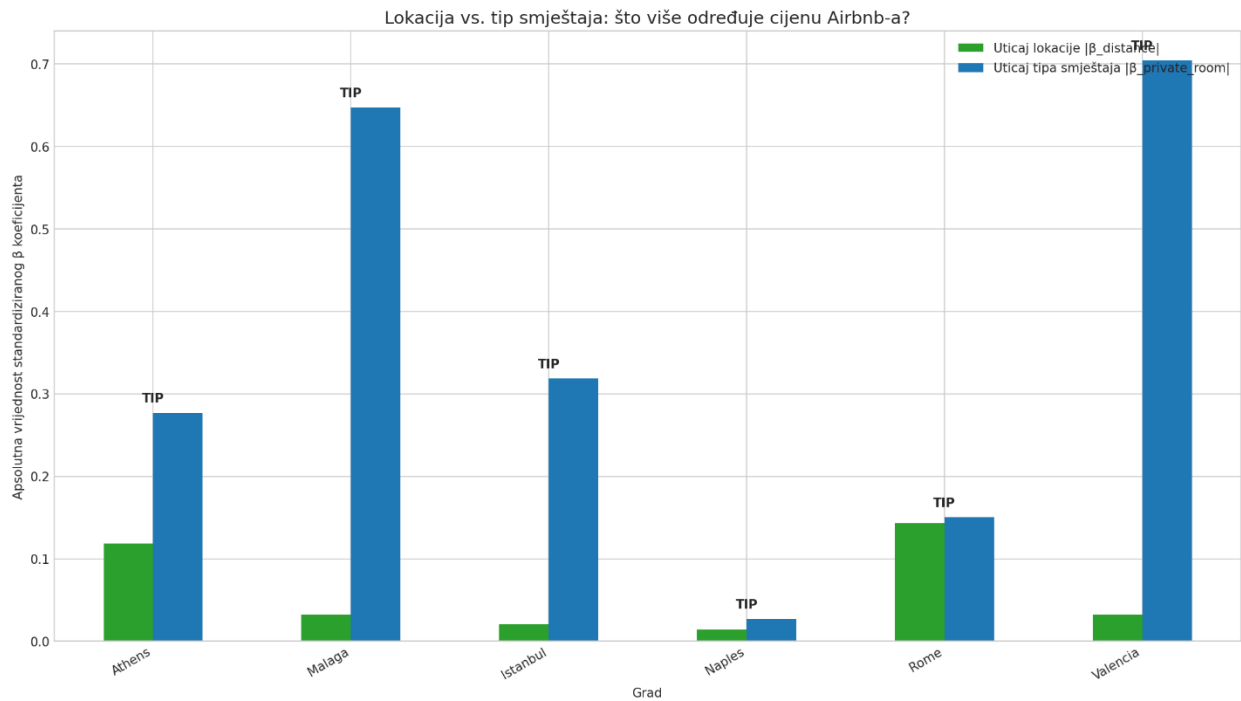
Scatter plot ocjene lokacije od strane gostiju u odnosu na cijenu potvrđuje pozitivnu vezu: smještaji s ocjenom lokacije 5.0 postižu znatno više prosječne cijene u odnosu na one s nižim ocjenama. Međutim, velika disperzija podataka ukazuje da visoka ocjena lokacije nije garancija visoke cijene - niti je niska ocjena prepreka za premium cijenu. Ovo sugerira da gosti cijenu percipiraju kroz kombinaciju više faktora, a ne isključivo kroz kvalitetu lokacije.



Slika 10: Scatterplot ocjene lokacije naspram cijene

3.6 Regresijska analiza - lokacija vs. tip smještaja

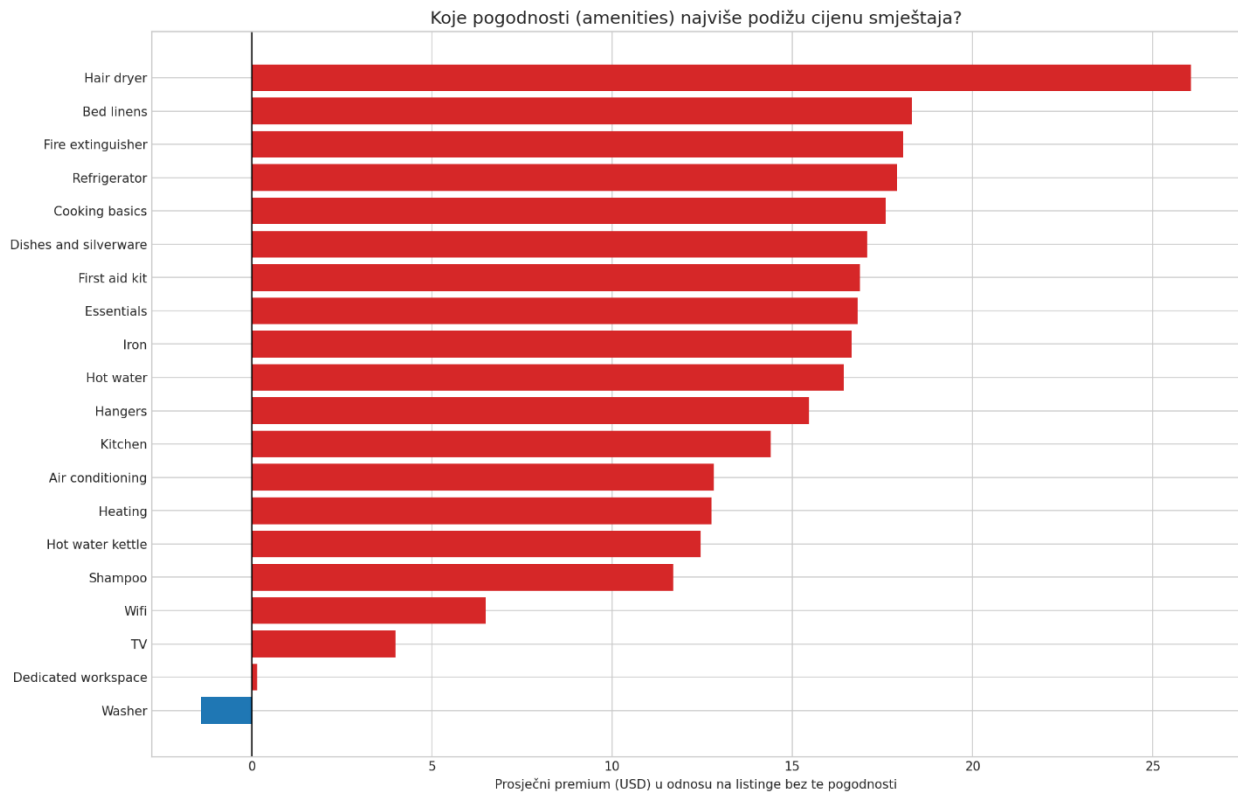
Komparacija standardiziranih β koeficijenata daje odgovor na centralnu hipotezu: u svih šest gradova tip smještaja dominira nad lokacijom kao cjenovni prediktor. Valencia i Malaga pokazuju dramatičnu dominaciju tipa smještaja ($\beta \approx 0,65-0,70$) uz gotovo zanemariv uticaj lokacije. Rim je jedina iznimka s uravnoteženim koeficijentima oba faktora ($\sim 0,15$ svaki). Heatmapa β koeficijenata multiple regresije potvrđuje da je Shared room konzistentno najjači negativni prediktor cijene (β od $-0,82$ u Rimu do $-1,25$ u Napulju), dok je kapacitet smještaja (accommodates) stabilan pozitivni prediktor u svim tržištima.



Slika 11: Lokacija vs tip smještaja

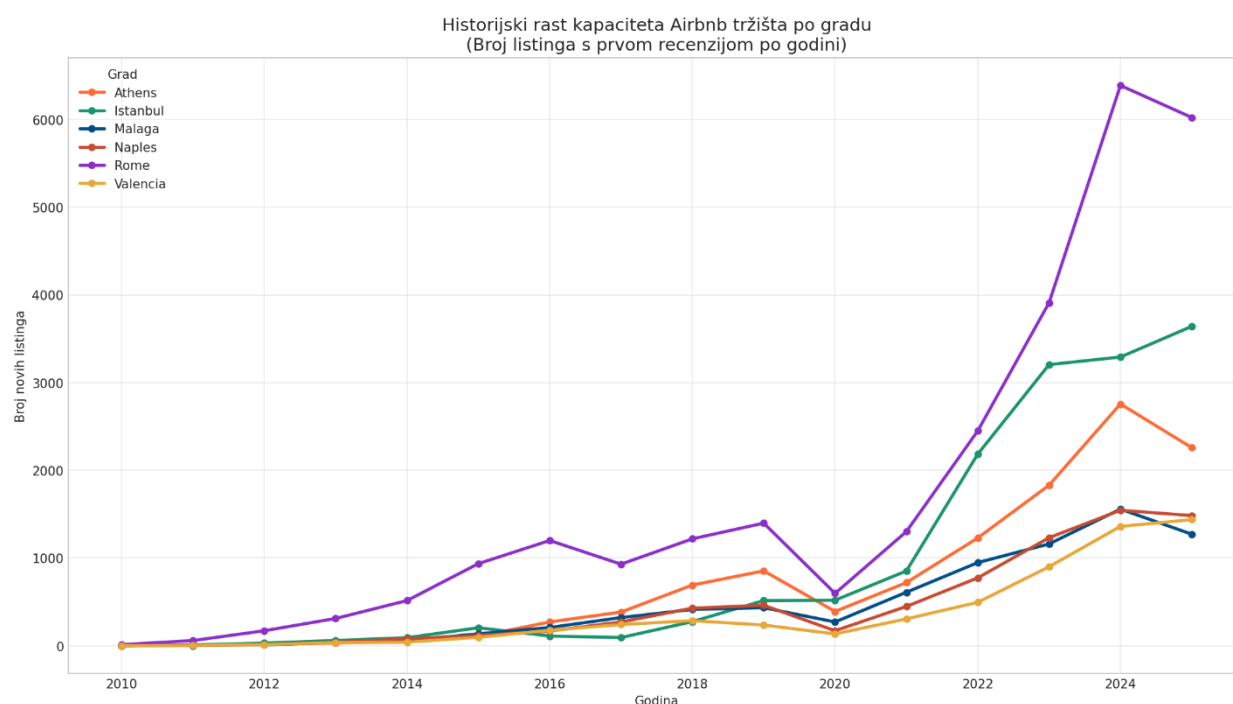
3.7 Napredna analiza

KMeans klasterizacija identificira četiri distinktna tržišna segmenta: crveni klaster predstavlja centralne smještaje s višim cijenama, plavi standardne centralne, zeleni periferne ekonomske, a ljubičasti atipične outliere - premium smještaje na periferiji koji odudaraju od očekivanog obrasca. Analiza pogodnosti otkriva koje amenities podižu cijenu. Zanimljivo, fen za kosu (~26 USD premija) i posteljina - krevetnina (~18 USD) nose znatno veću cjenovnu premiju od WiFi-a (~7 USD), što govori da je WiFi danas standard koji gosti podrazumijevaju, dok kompletna opremljenost signalizira viši nivo usluge i opravdava višu cijenu.



Slika 13: Pogodnosti koje najviše podižu cijenu smještaja

Historijski rast tržišta pokazuje ekspanziju u svim gradovima od 2010. s jasnim padom 2020. usljed pandemije i snažnim oporavkom nakon toga. Rim prednjači u apsolutnom rastu (~6.500 novih listinga u 2024.), dok Istanbul i Atena i dalje rastu ubrzano. Regulatorna analiza otkriva da Istanbul (42% nelicenciranih) i Valencia (40%) imaju znatan udio nelicenciranog poslovanja, za razliku od Atene (98,2% licenciranih). Value-for-money scatter plot identificira Atenu i Istanbul kao gradove s najboljim omjerom cijene i kvalitete, posebno u segmentu ispod 100 USD/noć s ocjenama $\geq 4,8$.



Slika 14: Historijski rast kapaciteta Airbnb tržišta

4 ZAKLJUČAK

Na osnovu analize 91.301 listinga iz šest mediteranskih gradova, sve četiri postavljene hipoteze su evaluirane.

H0 - POTVRĐENA. Cijena smještaja je determinirana kombinacijom lokacije i tipa smještaja, dok relativna važnost ovih faktora se sistematski razlikuje između gradova. Regresijska analiza potvrđuje ovu vezu kao statistički značajnu u svih šest tržišta.

H1 - DJELIMIČNO POTVRĐENA. Lokacija statistički značajno utiče na cijenu u četiri od šest gradova (najjače u Rimu $r = -0,47$ i Ateni $r = -0,20$). Napulj pokazuje obrnut efekt ($r = +0,08$), a Istanbul gotovo nikakav ($r = -0,04$), što ukazuje da H1 vrijedi kao generalni trend, ali ne kao univerzalni zakon.

H2 - POTVRĐENA. Cijeli stan dosljedno postiže višu cijenu od privatne sobe u svih šest gradova, s regresijski potvrđenom i statistički značajnom premiom koja varira po tržištu.

H3 - POTVRĐENA. Relativna važnost faktora se sistematski razlikuje: tip smještaja dominira u Malagi, Valenciji i Istanbulu, dok je Rim jedini grad s uravnoteženim uticajem oba faktora. Napulj pokazuje anomalan obrazac koji ukazuje na uticaj faktora izvan standardnog modela (obalna atraktivnost, prestiž kvarta). Ovo je najoriginalniji nalaz istraživanja i potvrđuje H3 uz važne nijanse.

Istraživanje ima određena ograničenja: podaci reflektiraju jedan vremenski presjek (septembar-oktobar 2025.) i ne obuhvataju sezonske varijacije, dok objavljene cijene ne moraju odgovarati realiziranim cijenama rezervacija. Predlažemo da buduća istraživanja uključuju longitudinalnu analizu, podatke o popunjenosti, te komparaciju s hotelskim tržištem.

LITERATURA

Inside Airbnb. (2025). *Listings and Neighbourhood Data* [Skup podataka za gradove: Atena (26.09.2025.), Malaga (30.09.2025.), Istanbul (29.09.2025.), Napulj (22.09.2025.), Rim (14.09.2025.) i Valencia (23.09.2025.)]. Preuzeto sa zvanične platforme Inside Airbnb: <https://insideairbnb.com/get-the-data/> [Pristupljeno: maj 2026.].